



Taller no paramétrico

Riobamba, Ecuador

Jeffrey S. Racine

Universidad McMaster

miércoles, 19 de abril de 2023

Consejos profesionales de diapositivas

¡Bienvenido!

- El sitio web con información de instalación para R, RStudio y $\text{\TeX}$ es
<https://jeffreyracine.github.io/RBworkshop>
- El repositorio de GitHub con código de ejemplo es
<https://github.com/JeffreyRacine/RBworkshop>
- No seas tímido, siéntete libre de hacer preguntas
- ¡Vámonos!

¡Bienvenido!

- Se le guiará a través de métodos kernel no paramétricos básicos usando R
- También, si es paciente, se le presentarán herramientas lanzadas recientemente para realizar investigaciones reproducibles.
- No se requieren conocimientos previos de análisis no paramétrico ni del lenguaje de programación R
- Todo el software está disponible de forma *gratuita* y es *de código abierto*.
- Para obtener descripciones más detalladas, consulte Racine ([2019](#)), Racine ([2012](#)) y Hayfield y Racine ([2008](#)).

Descripción general

- Espero que deje este taller armado con un conjunto moderno de herramientas de análisis de datos.
- Analicemos brevemente lo siguiente:
 - ¿Qué es R?
 - ¿Qué es RStudio?
 - ¿Qué es la regresión del núcleo?
 - ¿Qué es Cuarto?

Tipos de datos de fondo

R y tipos de datos

⚠ Importante

Datos *prefabricados antes del análisis* para que las funciones R puedan hacer su trabajo


- Es *crucial* comprender los diferentes tipos de datos en R
- Hay tres funciones de R que usaremos: `numeric()`, `factor()` y `ordered()`
- Estos corresponden a datos que son *números*, *categorías desordenadas* y *categorías ordenadas*, respectivamente.
- Presta mucha atención al siguiente ejemplo

R y tipos de datos

- A continuación se muestra un ejemplo de cómo proyectamos *nuestros* datos en R *antes* de analizarlos.
- Copie y pegue esto en un nuevo archivo R en RStudio, luego ejecútelo línea por línea

```
1  ## Generate some data: sex (unordered categorical), income (ordered categorical),
2  ## and height (numeric)
3  n <- 100
4  sex <- sample(c("Female","Male"),n,replace=TRUE,prob=c(.4,.6))
5  income <- sample(c("Low","Middle","High"),n,replace=TRUE,prob=c(.3,.5,.2))
6  height <- rnorm(n,mean=150,sd=20)
7  ## Note - by default these variables may not be the data types we desire
8  class(sex);class(income);class(height)
9  ## income is already numeric(), but sex and height are character()
10 ## sex is categorical and unordered, so cast as type factor()
11 sex <- factor(sex)
12 ## income is categorical and ordered, but we need to ensure intended order (it
13 ## will assume alphabetical ordering otherwise). Suppose you ignore it - let's
14 ## see what happens when we just cast as type ordered() using defaults
15 income <- ordered(income)
16 ## The levels are in alphabetical order, which we don't want
17 levels(income)
18 ## We shall reorder the ordered factor levels as intended using levels=...
19 income <- ordered(income,levels=c("Low","Middle","High"))
20 levels(income)
21 ## Check data types again
22 class(sex);class(income);class(height)
23 ## Note that with integers the default ordered() works fine
24 x <- sample(c(2,5,4,3,1),n,replace=TRUE)
25 x <- ordered(x)
26 levels(x)
```


Interfaz del editor RStudio R




Estimación de densidad de fondo

¿Paramétrico o no paramétrico?

Supongamos que necesitamos estimar la densidad $f(x)$ de alguna variable aleatoria numérica X

```
1  ## Let's simulate a random numeric sample from the normal distribution
2  set.seed(42)
3  n <- 1000
4  x <- rnorm(n)
5  ## Let's sort the data so we can graph x versus dnorm(x,...) using lines (type="l")
6  x <- sort(x)
7  ## Since we simulated the data, let's plot the true, known, parametric density
8  ## (we can't do this with actual data because the density of such data is, in
9  ## general, unknown)
10 plot(x, dnorm(x, mean=mean(x), sd=sd(x)), type="l", ylab="Parametric Density Estimate", xlab="X")
```



¿Paramétrico o no paramétrico?

- La función R `shapiro.test(x)` prueba la normalidad

Prueba de normalidad de
Shapiro-Wilk:`x`

Estadística de prueba	valor p
-----------------------	---------

0.9988	0.767
--------	-------

- Estos son datos *normales simulados* , y no podemos rechazar el valor nulo

Advertencia

¿Qué pasa si nos equivocamos en la densidad nula (es decir, qué pasa si rechazamos la nula)?

¿Paramétrico o no paramétrico?

- Ahora vamos a probar la normalidad de los datos reales, `eruptions`

Prueba de normalidad de Shapiro-
Wilk: `eruptions`

Estadística de prueba	valor p
0.8459	9.036e-16 * *
	*

Advertencia

Oh oh... Supongo que descartamos el modelo paramétrico normal... ¿Qué sigue?

¿Paramétrico o no paramétrico?


- Información actual $(X_i, i = 1, \dots, n)$ rara vez se extrae de las distribuciones paramétricas simples utilizadas en *la teoría del muestreo*
- La teoría del muestreo describe *estadísticas resumidas*, por ejemplo, *promedios* de datos reales o *promedios* de desviaciones al cuadrado, como

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i \quad \text{or} \quad \hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \hat{\mu})^2$$

- Pero necesitamos estimar la *densidad de los datos reales* (es decir, $f(x)$), no la *densidad de alguna estadística de resumen* (es decir, $f(\hat{\mu})$)


¿Paramétrico o no paramétrico?

- A continuación se muestra una estimación de densidad no paramétrica y *una alfombra* de datos para los `eruptions` datos (es bimodal y asimétrica)



¿Paramétrico o no paramétrico?

- *A continuación se muestra una estimación paramétrica normal y no paramétrica (recuerde que el modelo paramétrico normal ha sido rechazado)*



¿Paramétrico o no paramétrico?

- Aquí radica el quid del problema paramétrico.
- Anotamos algún modelo paramétrico que se extrae de un espacio *denso* de funciones (su número es *incontable*)
- Una suposición muy importante es que *este modelo paramétrico es el modelo verdadero* , y todas las propiedades del modelo (imparcialidad, consistencia, etc.) dependen *crucialmente* de que este sea el caso.
- Pero si habla en serio, *pruebe* inmediatamente su modelo para ver si tiene las especificaciones correctas.
- ¿Qué sucede si se rechaza el modelo paramétrico, como sucede a menudo?


Datos numéricos esenciales no paramétricos

Datos numéricos

- Los métodos paramétricos requieren que el usuario haga *suposiciones muy fuertes* sobre el *proceso de generación de datos* (DGP)
- Acabamos de considerar la estimación de la densidad, pero exactamente el mismo problema afecta a todos los análisis paramétricos (es decir, regresión, etc.)
- Consideraremos, en cambio, estimadores *kernel no paramétricos*
- Un *núcleo* es simplemente una función de peso, que para datos *numéricos* denotamos por $K(Z_i)$ donde $Z_i = (x - X_i)/h$
- Damos *mayor* peso a las observaciones cercanas a x (es decir, pequeño Z_i) que a los que yacen más lejos (es decir, grandes Z_i)

¿No liso o liso?

- A continuación se muestran estimaciones de densidad no paramétrica suave y no suave para la variable *numérica* **eruptions**



¿No liso o liso?

- El estimador de densidad de histograma no paramétrico no suave es

$$f_H(x) = \frac{1}{nh} \sum_{i=1}^n \mathbf{1}(X_i \text{ is in the same bin as } x)$$

- Este estimador tiene inconvenientes, que incluyen
 - no es particularmente *eficiente* en el sentido estadístico
 - la discontinuidad del estimador presenta obstáculos si se requieren derivados ($df_H(x)/dx$ es 0 o indefinido)

Estimación suave de densidad univariante

- Considere una función kernel suave simétrica que satisface $K(z) \geq 0$ y $\int_{-\infty}^{\infty} K(z) dz = 1$
- El estimador de densidad kernel no paramétrico suave es

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right)$$

- Este estimador es dominante en entornos aplicados, aunque *el sesgo de límite* puede ser un problema (existen correcciones simples, vea `npuniden.boundary()` en el `np` paquete)


Estimación suave de densidad univariante

! Importante

- La función del núcleo $K(z)$ es relativamente poco importante (imparte *suavidad* en la estimación, donde las funciones suaves son funciones *continuamente diferenciables*)
 - el ancho de banda h es crucial (gobierna la compensación sesgo-varianza)
-
- La *cercanía* está determinada por un *ancho de banda* , denotado h
 - Nosotros elegimos h para minimizar el *riesgo de error cuadrático* y compensar el *sesgo* por la *varianza* de la muestra en cuestión
 - Para lograr esto, utilizamos métodos *basados en datos* para seleccionar h (por ejemplo, validación cruzada de mínimos cuadrados)

Estimación suave de densidad univariante

```
1 library(np)
2 data(faithful)
3 fhat <- npudens(~eruptions,data=faithful)
4 plot(fhat,neval=250,plot.errors.method="bootstrap")
```



Estimación de la densidad de juntas lisas

- Hasta ahora hemos considerado densidades univariadas ($X \in \mathbb{R}^1$)
- Dejar $X \in \mathbb{R}^q$ denota un vector numérico de dimensión q
- Dejar $f(x) = f(x_1, x_2, \dots, x_q)$ denota una PDF conjunta evaluada en $x = (x_1, x_2, \dots, x_q)'$
- Dejar $\{X_1, X_2, \dots, X_n\}$ representar n sorteos de un vector aleatorio numérico X , donde el i ésimo sorteo se denota por $X_i = (X_{i1}, X_{i2}, \dots, X_{iq})$

Estimación de la densidad de juntas lisas


- El estimador de densidad kernel multivariado es

$$\hat{f}(x) = \frac{1}{nh_1 \dots h_q} \sum_{i=1}^n K \left(\frac{x_1 - X_{i1}}{h_1}, \dots, \frac{x_q - X_{iq}}{h_q} \right)$$

- $K(\cdot)$ es un kernel *multivariable* (típicamente el *producto* de kernels univariantes - tenemos mucha flexibilidad aquí)
- Seguimos utilizando métodos basados en datos (por lo general, validación cruzada) para la selección de ancho de banda cuando $q \geq 1$ (los anchos de banda óptimos difieren según las variables, es decir, $h_1 \neq h_2$, etc.)

Estimación de la densidad de juntas lisas

```
1 library(np)
2 data(faithful)
3 fhat <- npudens(~eruptions+waiting,data=faithful)
4 plot(fhat,theta=330,xtrim=-0.05,neval=75,view="fixed",main="")
```



Datos categóricos esenciales no paramétricos

Variables categóricas

- Consideramos la densidad de variables aleatorias distribuidas continuamente $X \in \mathbb{R}$, pero también nos ocupamos de la función de probabilidad de las variables categóricas $X \in \mathcal{D}$ donde $\mathcal{D}$ es un conjunto discreto
- Podríamos suponer un modelo paramétrico para la función de probabilidad de $X \in \mathcal{D}$ pero nos enfrentamos exactamente al mismo problema que enfrentamos antes
- La contraparte categórica no uniforme del histograma se denomina estimador de *frecuencia* o probabilidad *empírica* y, al igual que el histograma, tiene algunos inconvenientes.

Estimación de probabilidad univariada

- Dejar $X \in \mathcal{D} = \{0, 1, \dots, c - 1\}$ ser categórico
- X puede ser *desordenado* (`factor()` en R) u *ordenado* (`ordered()` en R)
- El estimador *de frecuencia* no paramétrico de $p(x)$ es

$$\begin{aligned} p_n(x) &= \frac{\#X_i \text{ equal to } x}{n} \\ &= \frac{1}{n} \sum_{i=1}^n \mathbf{1}(X_i = x) \end{aligned}$$

Estimación de probabilidad univariada

- El estimador kernel no paramétrico *desordenado* $\hat{p}(x)$ es

$$\hat{p}(x) = \frac{1}{n} \sum_{i=1}^n L(X_i, x, \lambda)$$


- $L(\cdot)$ es una función del kernel *desordenada* dada por

$$L(X_i, x, \lambda) = \begin{cases} 1 - \lambda & \text{if } X_i = x \\ \lambda / (c - 1) & \text{otherwise} \end{cases}$$

- λ es un *parámetro de suavizado* (contraparte del *ancho de banda* h)

Ejemplo - Probabilidad desordenada

```
1 n <- 250
2 set.seed(42)
3 sex <- sample(c("Female", "Male"), n, replace=TRUE, prob=c(.4, .6))
4 sex <- factor(sex)
5 phat <- npudens(~sex)
6 plot(phat, plot.errors.method="bootstrap")
```



Estimación de probabilidad univariada

- Dejar $X \in \mathcal{D} = \{0, 1, \dots, c - 1\}, c \geq 2$, ser *ordenado*
- El estimador kernel no paramétrico *ordenado* $\hat{p}(x)$ es


$$\hat{p}(x) = \frac{1}{n} \sum_{i=1}^n l(X_i, x, \lambda)$$

- $l(X_i, x, \lambda)$ es una función kernel *ordenada* dada por

$$l(X_i, x, \lambda) = \frac{\lambda^{d_{xi}}}{\Lambda_i}$$

Ejemplo: probabilidad ordenada

```
1 n <- 250
2 set.seed(42)
3 income <- sample(c("Low", "Middle", "High"), n, replace=TRUE, prob=c(.3, .5, .2))
4 income <- ordered(income, levels=c("Low", "Middle", "High"))
5 phat <- npudens(~income)
6 plot(phat, plot.errors.method="bootstrap")
```



Datos mixtos esenciales no paramétricos

Estimación de densidad de datos mixtos

- Los estadísticos saben que $f(x)$ y $p(x)$ ambas se denominan funciones *de densidad* (la diferencia radica en su *medida* ; la última utiliza una medida *de conteo*), por lo que adoptamos $f(x)$
- Suponga que tiene una densidad conjunta definida sobre tipos de datos mixtos, digamos, un numérico ($X^c \in \mathbb{R}$) y uno desordenado ($X^d \in \mathcal{D}$ con cardinalidad c)
- Nos gustaría modelar su función de densidad conjunta $f(x) = f(x^c, x^d)$, donde los superíndices c y d denotan tipos de datos continuos y discretos, respectivamente, y donde $x = (x^c, x^d) \in \mathbb{R} \times \mathcal{D}$

Estimación de densidad de datos mixtos

- El estimador kernel de $f(x^c, x^d)$ es

$$\hat{f}(x^c, x^d) = \frac{1}{n} \sum_{i=1}^n \frac{1}{h} K \left(\frac{X_i^c - x^c}{h} \right) L(X_i^d, x^d, \lambda)$$

- $K(\cdot)$ y $L(\cdot)$ son funciones kernel (univariadas) *numéricas y desordenadas*, respectivamente
- Si tuviera una variable numérica y una *ordenada*, usaría el núcleo ordenado $l(X_i^d, x^d, \lambda)$ arriba
- Ahora consideremos el caso *general* de densidad de datos mixtos multivariados

Estimación de densidad de datos mixtos

- En entornos multivariantes generales, la función de densidad de probabilidad $f(x)$ podría usar alguna combinación de q numérico, r desordenado, y s tipos de variables ordenadas (x y X_i son $q + r + s$ -vectores)
- El kernel (producto) para estimar la función de densidad conjunta es

$$\prod_{j=1}^q h_j^{-1} K \left(\frac{x_j^c - X_{ij}^c}{h_j} \right) \prod_{j=1}^r L(X_{ij}^u, x_j^u, \lambda_j^u) \prod_{j=1}^s l(X_{ij}^o, x_j^o, \lambda_j^o)$$

- Todo lo que estamos haciendo aquí es usar la *función de kernel adecuada* para cada tipo de datos.

Estimación de densidad de datos mixtos

- Dejar $\gamma = (h_1, \dots, h_q, \lambda_1^u, \dots, \lambda_r^u, \lambda_1^o, \dots, \lambda_s^o)$
- Llame a la función kernel del producto en la diapositiva anterior el kernel *generalizado*, es decir, deje que la expresión se escriba como

$$K_{\gamma}(X_i, x) = \prod_{j=1}^q [\dots] \prod_{j=1}^r [\dots] \prod_{j=1}^s [\dots]$$

- Con x, X_i ser $q + r + s$ vectores, escribimos $\hat{f}(x)$ como

$$\hat{f}(x) = \frac{1}{n} \sum_{i=1}^n K_{\gamma}(X_i, x)$$

Estimación de densidad de datos mixtos

- El punto clave es que *una vez que envía sus datos* , las funciones R en el **np** paquete saben *exactamente* qué hacer
- Usan *automáticamente* el kernel apropiado para el tipo de datos apropiado (numérico, factorial, ordenado)
- Los métodos de ancho de banda basados en datos se ajustan automáticamente al tipo de datos
- Los métodos de inferencia (intervalos de confianza, pruebas de significancia en regresión) hacen lo mismo
- Consideremos un ejemplo rápido

Ejemplo: densidad de datos mixta

- Usamos `wage1` los datos de Wooldridge y consideramos dos variables, una numérica (`lwage`) y otra ordenada (`numdep`)
- `lwage` es el logaritmo de los ingresos promedio por hora de un individuo y `numdep` es su número de dependientes
- El número de observaciones en cada *celda* se tabula en [la Tabla 1](#)

Tabla 1: Recuento del número de dependientes
presentes en 526 hogares por celda

número dep	0	1	2	3	4	5	6
cuenta	252	105	99	45	dieciséis	7	2

- Estimamos $\hat{f}(lwage, numdep)$ y trazarlo en [la figura 1](#)

Ejemplo: densidad de datos mixta

- A continuación se muestra el código R para estimar y trazar la densidad conjunta (usamos el `plot3D` paquete y reformateamos los datos para representar este gráfico)

```
1 library(np)
2 library(plot3D)
3 data(wage1)
4 bw <- npudensbw(~lwage+ordered(numdep),data=wage1)
5 numdep.seq <- with(wage1,sort(unique(numdep)))
6 lwage.seq <- with(wage1,seq(min(lwage),max(lwage),length=50))
7 wage1.eval <- expand.grid(numdep=ordered(numdep.seq),lwage=lwage.seq)
8 fhat <- fitted(npudens(bws=bw,newdata=wage1.eval))
9 ## Hack since scatter3D converts ordered 0-6 to numeric 1-7
10 scatter3D(as.numeric(wage1.eval[,1])-1,wage1.eval[,2],fhat,
11           ylab="Log-Wage",
12           xlab="Number of Dependants",
13           zlab="Joint Density",
14           ticktype="detailed",
15           angle=15,
16           box=TRUE,
17           type="h",
18           grid=TRUE,
19           col="blue",
20           colkey=FALSE)
```

Ejemplo: densidad de datos mixta




Figura 1: Estimación de densidad kernel bivariada de datos mixtos para la PDF conjunta de lwage (numérico) y numdeps (ordenado)

Regresión no paramétrica

Regresión no paramétrica

- La función media condicional $g(x) := \mathbb{E}(Y|X = x)$ para numérico $Y \in \mathbb{R}$ se define como

$$g(x) = \int y \frac{f(y, x)}{f(x)} dy = \frac{m(x)}{f(x)} \quad (1)$$

- Empecemos con $X \in \mathbb{R}^1$ (es decir, un predictor numérico)
- Nuestro objetivo es estimar el modelo de regresión desconocido $y = g(x) + \varepsilon$ sin suponer que, por ejemplo, $g(x) = \beta_0 + \beta_1 x$

Regresión no paramétrica

- La regresión es *difícil* porque $f(y, x)$ y $f(x)$ son desconocidos
- Se pueden estimar *consistentemente* usando $\hat{f}(y, x)$ y $\hat{f}(x)$
- Para distribución continua $Y \in \mathbb{R}$, el estimador de regresión kernel *constante local* reemplaza el *desconocido* $f(y, x)$ y $f(x)$ con *known* $\hat{f}(y, x)$ y $\hat{f}(x)$ en (1), por eso

$$\hat{g}(x) = \int y \frac{\hat{f}(y, x)}{\hat{f}(x)} dy = \frac{\hat{m}(x)}{\hat{f}(x)} \quad (2)$$

Regresión no paramétrica

- Para $X \in \mathbb{R}^1$, estimamos $g(x)$ reemplazando lo desconocido $f(x)$ en (1) con

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K \left(\frac{x - X_i}{h} \right),$$

- y reemplazando lo desconocido $f(y, x)$ en (1) con

$$\hat{f}(y, x) = \frac{1}{nh_y h} \sum_{i=1}^n K \left(\frac{y - Y_i}{h_y} \right) K \left(\frac{x - X_i}{h} \right)$$

Regresión no paramétrica

- Algunas simplificaciones matemáticas de $\hat{g}(x)$ lleva a

$$\hat{g}(x) = \sum_{i=1}^n Y_i \left\{ \frac{K\left(\frac{X_i - x}{h}\right)}{\sum_{i=1}^n K\left(\frac{X_i - x}{h}\right)} \right\} = \sum_{i=1}^n Y_i W_i(x)$$

- Con datos mixtos multivariados X (es decir, x y X_i son $q + r + s$ -vectores) reemplazamos $K(\cdot)$ con $K_\gamma(X_i, x)$
- La función de regresión no paramétrica estimada es

$$y = \hat{g}(x) + \hat{\epsilon} \quad (3)$$

Ilustración de datos simulados

```
1 library(np)
2 set.seed(42)
3 n <- 1000
4 x <- sort(runif(n))
5 dgp <- cos(2*pi*x)
6 y <- dgp + rnorm(n,sd=0.25*sd(dgp))
7 ghat <- npreg(y~x)
8 plot(x,y,cex=0.5,col="grey",xlab="X",ylab="Y")
9 lines(x,dgp)
10 lines(x,fitted(ghat),col=2)
11 abline(ghat.ols <- lm(y~x),col=3)
12 legend("top",c("DGP","Kernel","OLS"),col=1:3,lty=1,bty="n")
```




Ilustración de datos simulados: OLS

¿ Cómo funciona el modelo lineal paramétrico simple [ghat.ols](#) para estos datos simulados?

	Estimar	Estándar Error	valor t	Pr(> t)
(Interceptar)	0.03148	0.04529	0.695	0.4872
X	-0.04666	0.07966	-0.5858	0.5582

Modelo lineal de ajuste: $y \sim x$

Observaciones	estándar residual Error	R^2	Equilibrado R^2
1000	0.7338	0.0003437	-0.000658



Advertencia

Oh oh... este modelo paramétrico lineal realmente apesta... el modelo no paramétrico tiene un R^2 de 0,9411 (el modelo paramétrico tiene un R^2 de 0.0003437 y un valor ajustado *negativo* R^2)

Efectos marginales

- el univariado X La función de efectos marginales es simplemente la función de la primera derivada parcial y se define como

$$\begin{aligned}\beta(x) &= \frac{dg(x)}{dx} = \frac{f(x)m'(x) - m(x)f'(x)}{f^2(x)} \\ &= \frac{m'(x)}{f(x)} - g(x) \frac{f'(x)}{f(x)}\end{aligned}\tag{4}$$


- Nosotros construimos $\hat{\beta}(x)$ por reemplazo $f(x), m'(x), m(x)$, y $f'(x)$ en (4) con $\hat{f}(x), \hat{m}'(x), \hat{m}(x)$, y $\hat{f}'(x)$

Efectos marginales

- Recuerde las definiciones de las funciones media condicional y de efectos marginales, $g(x)$ y $\beta(x)$
- Implican densidades conjuntas y marginales desconocidas y sus derivadas, que son funciones de x y y
- Si tuviera la tarea de estimar $\beta(x)$, es difícil justificar la suposición de que $\beta(x)$ es *constante* (es decir, alguna constante β eso *no* es función de x como $\beta(x)$)
- Pero esto es *exactamente* lo que se supone para el popular modelo de regresión lineal (es decir, $\beta(x) = dy/dx = \beta_1$, una *constante*)

Ejemplo: efectos marginales simulados

```
1 plot(ghat,gradients=TRUE,neval=250)
2 lines(x,-2*pi*sin(2*pi*x),col=2)
3 abline(h=coef(ghat.ols)[2],col=3)
4 legend("topleft",c("Kernel ME","DGP ME","Linear ME"),col=1:3,lty=1,bty="n")
```



Efectos marginales de datos mixtos

- Considere una función media condicional multivariante $g(x)$ donde x está compuesto por q continuo, r desordenado, y s predictores ordenados
- Como en el ejemplo univariado anterior, si el j el predictor es continuo, es decir, $x_j \in \mathbb{R}$, entonces $\hat{\beta}_j(x)$ es la primera función derivada parcial de $\hat{g}(x)$ Con respecto a j el predictor, es decir,

$$\hat{\beta}_j(x) = \frac{\partial \hat{g}(x)}{\partial x_j} = \frac{\hat{m}^{(j)}(x)}{\hat{f}(x)} - \hat{g}(x) \frac{\hat{f}^{(j)}(x)}{\hat{f}(x)}$$

Efectos marginales de datos mixtos multivariados

- Si el predictor está desordenado en $\mathcal{D} = \{a, b, c\}$, entonces $\hat{\beta}_j(x)$ es la diferencia entre $\hat{g}(x)$ cuando $x_j^u = b$ versus $\hat{g}(x)$ cuando $x_j^u = a$, y entre $\hat{g}(x)$ evaluado en $x_j^u = c$ contra en $x_j^u = a$ (a es la categoría *base*)

$$\hat{\beta}_j(x) = \hat{g}(x_{(-j)}, x_j = l) - \hat{g}(x_{(-j)}, x_j = a), \quad l = b, c$$

- Si el predictor está ordenado, tenemos dos opciones, a saber, tomar diferencias como en el caso desordenado, o tomar diferencias entre elementos *sucesivos* del conjunto ordenado (es decir, entre a y b entonces entre b y c)

Regresión multivariada






- Usamos `wage1` los datos de Wooldridge que contienen predictores numéricos y categóricos ([enlace a la descripción de salario1](#))
- Hacemos una regresión `lwage` en predictores categóricos `female` y `married` predictores numéricos `educ`, `exper` y `tenure`
- La fórmula para los modelos de regresión es
`lwage~female+married+educ+exper+tenure`
- Para el modelo no paramétrico, esto solo enumera los predictores
- Para el modelo paramétrico impone estructura lineal

Regresión no paramétrica multivariada

```
1 library(np)
2 data(wage1)
3 ghat <- npreg(lwage ~ female + married + educ + exper + tenure, data=wage1, regtype="ll")
4 summary(ghat)
5 ##
6 ## Regression Data: 526 training points, in 5 variable(s)
7 ##               female married   educ   exper   tenure
8 ## Bandwidth(s): 1.058363e-07 0.2881137 5.148991 7.185339 28.00628
9 ##
10 ## Kernel Regression Estimator: Local-Linear
11 ## Bandwidth Type: Fixed
12 ## Residual standard error: 0.36823
13 ## R-squared: 0.520417
14 ##
15 ## Continuous Kernel Type: Second-Order Gaussian
16 ## No. Continuous Explanatory Vars.: 3
17 ##
18 ## Unordered Categorical Kernel Type: Aitchison and Aitken
19 ## No. Unordered Categorical Explanatory Vars.: 2
```


Gráficas de regresión parcial

```
1 ## We run out of graph axis dimensions with > 2 predictors, so it is common to
2 ## construct partial plots that plot the fitted model versus each predictor
3 ## separately holding the off-axis predictors at, say, their median value (you
4 ## can change this - see ?npplot and the argument xq)
5 par(mfrow=c(2,3))
6 plot(ghat,plot.errors.method="bootstrap")
```



Gráficas de efectos marginales (gradiente)

```
1 par(mfrow=c(2,3))  
2 plot(ghat,gradients=TRUE,plot.errors.method="bootstrap")
```



Pruebas $H_0: \beta_j = 0$ (Significado MCO)

Un simple t -test se usa para probar $H_0: \beta_j = 0$

```
1 ghat.ols <- lm(lwage ~ female + married + educ + exper + tenure, data=wage1)
2 summary(ghat.ols)
3 ##
4 ## Call:
5 ## lm(formula = lwage ~ female + married + educ + exper + tenure,
6 ##     data = wage1)
7 ##
8 ## Residuals:
9 ##      Min       1Q   Median       3Q      Max
10 ## -1.87254 -0.27256 -0.03779  0.25349  1.23666
11 ##
12 ## Coefficients:
13 ##              Estimate Std. Error t value Pr(>|t|)
14 ## (Intercept)    0.330268   0.106391   3.104  0.00201 **
15 ## femaleMale     0.285530   0.037264   7.662 9.00e-14 ***
16 ## marriedNotmarried -0.125739  0.039986  -3.145  0.00176 **
17 ## educ           0.083905   0.006973  12.033 < 2e-16 ***
18 ## exper           0.003134   0.001682   1.863  0.06300 .
19 ## tenure          0.016867   0.002955   5.707 1.93e-08 ***
20 ## ---
21 ## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
22 ##
23 ## Residual standard error: 0.4125 on 520 degrees of freedom
24 ## Multiple R-squared:  0.4036, Adjusted R-squared:  0.3979
25 ## F-statistic: 70.38 on 5 and 520 DF,  p-value: < 2.2e-16
```

Pruebas $H_0: \beta_j(x) = 0$ (Significado)

- Las hipótesis nula y alternativa son

$$H_0: \beta_j(x) = 0 \text{ for all } x \text{ (a.e.)}$$

$$H_A: \beta_j(x) \neq 0 \text{ for some } x \text{ on a set with + measure}$$

- Una estadística de prueba factible $\hat{\lambda} \geq 0$ es dado por

$$\hat{\lambda} = \begin{cases} n^{-1} \sum_{i=1}^n \hat{\beta}_j(X_i)^2 & \text{if } x_j \in \mathbb{R} \\ n^{-1} \sum_{i=1}^n \sum_{l=1}^{c-1} \hat{\beta}_j(X_i)^2 & \text{if } x_j \in \mathcal{D} \end{cases}$$

- Un procedimiento de arranque proporciona la distribución nula

Pruebas $H_0: \beta_j(x) = 0$ (Significado)

un arranque λ -test se usa para probar $H_0: \beta_j(x) = 0 \forall x(a)$

```
1 npsigtest(ghat)
2 ##
3 ## Kernel Regression Significance Test
4 ## Type I Test with IID Bootstrap (399 replications, Pivot = TRUE, joint = FALSE)
5 ## Explanatory variables tested for significance:
6 ## female (1), married (2), educ (3), exper (4), tenure (5)
7 ##
8 ##               female   married    educ    exper    tenure
9 ## Bandwidth(s): 1.058363e-07 0.2881137 5.148991 7.185339 28.00628
10 ##
11 ## Individual Significance Tests
12 ## P Value:
13 ## female < 2.22e-16 ***
14 ## married 0.0050125 **
15 ## educ    < 2.22e-16 ***
16 ## exper   < 2.22e-16 ***
17 ## tenure  < 2.22e-16 ***
18 ## ---
19 ## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Contrafactuales

- La función R `fitted(...)` extrae valores ajustados para cada observación de muestra
- Supongamos que queremos valores ajustados para *valores específicos* de los predictores.
- Usamos la función R `predict(..., newdata=...)` donde `newdata` apunta a un marco de datos que contiene *named y cast X* valores para los que queremos predicciones
- Generemos un marco de datos llamado que `df` contenga 1 fila para generar el salario logarítmico previsto para hombres solteros con educación media, antigüedad laboral y experiencia laboral.

Contrafactuales

```
1 attach(wage1)
2 df <- data.frame(female = factor("Male", levels=levels(female)),
3                 married = factor("Notmarried", levels=levels(married)),
4                 educ = median(educ),
5                 tenure = median(tenure),
6                 exper = median(exper))
7 head(df)
8 ##   female   married educ tenure exper
9 ## 1   Male Notmarried  12      2   13.5
10 predict(ghat, newdata=df)
11 ## [1] 1.699066
12 ## Or you could use ghat <- npreg(...,newdata=df) and fitted(ghat)
13 ## ghat <- npreg(lwage ~ female + married + educ + exper + tenure,
14 ##              data=wage1,
15 ##              regtype="ll",
16 ##              newdata=df)
17 ## fitted(ghat)
```

Si **df** tuviera varias filas, obtendríamos una predicción para cada fila (es decir, un vector de predicciones)

Quarto: Documentos técnicos reproducibles

Un flujo de trabajo subóptimo

- La forma antigua de investigar es ejecutar sus análisis usando R, luego copiar manualmente figuras y tablas en un procesador de texto (por ejemplo, MS Word) o una máquina tipográfica (por ejemplo, $\text{\TeX}$)
- Así que usted termina manteniendo archivos narrativos, de figuras y códigos separados y siendo su coordinador intermediario.
- ¡Y se ha comprometido previamente con un formato de salida!
- Luego encuentra un código o un error de datos y necesita rehacer figuras, tablas, etc., o necesita cambiar los formatos de salida
- Este es un proceso brutalmente ineficiente y propenso a errores porque requiere un intermediario (es decir, ¡usted!)

Un flujo de trabajo optimizado

- Quarto coloca su código y narrativa en el mismo archivo
- Liberados de las funciones de coordinación, surgen nuevas posibilidades
 - ahora se refiere *automáticamente* a los resultados analíticos
 - ahora describe *condicionalmente* los resultados analíticos
- Si se actualiza el código o los datos, las figuras y tablas se actualizan automáticamente en su documento de salida
- Quizás lo mejor de todo es que su archivo Quarto en cualquier formato de salida imaginable sin [pandoc](#)
- ([Quarto](#) , [GitHub](#) y [renv](#) son compatibles con [RStudio](#))




Original text

Cambridge University Press.

[Contribute a better translation](#)

Interfaz del editor RStudio Quarto



Resumen

- Apenas hemos arañado la superficie y nos hemos saltado detalles técnicos.
- Sin embargo, ahora tiene cierta perspectiva y tiene acceso a herramientas modernas.
- Puede consultar Racine ([2019](#)) si desea profundizar más (pruebas detalladas, código R, ejemplos, etc.)
- Muchos de los enlaces en estas diapositivas también pueden ser útiles.
- Puede ponerse en contacto conmigo en racinej@mcmaster.ca
- ¡Ha sido un placer guiarte! ¡Adiós!

Referencias

- Hayfield, Tristen y Jeffrey S. Racine. 2008. "Econometría no paramétrica: el paquete np ". *Revista de software estadístico* 27 (5): 1–32. <https://doi.org/10.18637/jss.v027.i05> .
- Racine, Jeffrey S. 2012. "RStudio: un IDE independiente de la plataforma para R y Sweave ". *Revista de Econometría Aplicada* 27 (1): 167–72. <http://www.jstor.org/stable/41337225> .
- . 2019. *Una introducción a la teoría y práctica avanzadas de la econometría no paramétrica: un enfoque replicable usando R* . Prensa de la Universidad de Cambridge. <https://doi.org/10.1017/9781108649841> .

